




Regression Analysis

РЕГРЕССИОННЫЙ АНАЛИЗ

Выполнила: Авдониная Лада Вадимовна, гр. 23202

Преподаватель: Яхьяева Гульнара Эркиновна

Что такое регрессия?

Регрессия — это метод прогнозирующего моделирования, который устанавливает взаимосвязь между зависимой и одной или несколькими независимыми переменными.

1 Обычная регрессия

Предсказываем число

2 Логистическая регрессия

Предсказываем категорию или
вероятность

В двух словах: мы хотим по известным признакам предсказать число или вероятность.

Когда и где используют регрессию?

Практически везде, где нужно предсказать число или вероятность.



Недвижимость


Стоимость квартиры определяется местоположением, количеством спален, площадью

Предприятия используют регрессионный анализ для прогнозирования возможностей и угроз.



Бизнес

Прогнозирование спроса, ставок, количества покупателей



Финансы

Прогнозирование прибыли корпораций, страховых случаев

Основные типы регрессии

Типы регрессии определяются тремя показателями: количеством зависимых переменных, типом зависимых переменных, формой границы регрессии.

1

Линейная

2

Полиномиальная

3

Ridge

4

Lasso

5

ElasticNet

6

Логистическая

Линейная регрессия

Первый вид регрессионного анализа, который тщательно изучен и широко используется. Предполагает линейную зависимость между объектом и его предикторами.

Уравнение линии регрессии:

$$y_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip} + \varepsilon_i = x_i^T \beta + \varepsilon_i, \quad i = 1, \dots, n$$

Мы должны найти наиболее подходящую прямую (или плоскость в многомерном случае), которая устанавливает взаимосвязь между зависимой переменной (y) и независимыми переменными (x).



Матричная форма линейной регрессии

$$y = X\beta + \epsilon$$


$$y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} \quad X = \begin{pmatrix} x_1^T \\ x_2^T \\ \vdots \\ x_n^T \end{pmatrix} = \begin{pmatrix} 1 & x_{11} & \cdots & x_{1p} \\ 1 & x_{21} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & x_{n1} & \cdots & x_{np} \end{pmatrix} \quad \beta = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \\ \vdots \\ \beta_p \end{pmatrix} \quad \epsilon = \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{pmatrix}$$

Метод наименьших квадратов

Для получения линии наилучшего соответствия используется метод наименьших квадратов, который минимизирует сумму квадратов вертикальных отклонений.

$$\min_{\beta} \|X\beta - y\|^2$$

Мы предполагаем, что наблюдения являются случайными отклонениями от лежащей в основе зависимости между y и x .



Допущения линейной регрессии

- 1 Отсутствие ошибок в измерении предикторов**
Предполагаем, что переменные измерены идеально точно
- 2 Гомоскедастичность**
Ошибки измерения не зависят от величины X — одинаковый разброс на всём диапазоне
- 3 Независимость ошибок**
Ошибка на одном объекте не влияет на ошибку на другом
- 4 Отсутствие мультиколлинеарности**
Признаки не должны быть почти одинаковыми
- 5 Линейная связь**
Связь между X и Y должна быть линейной

 Требуется тщательный анализ набора данных перед применением линейной регрессии.


Полиномиальная регрессия

Моделируем взаимосвязь между независимой переменной x и зависимой переменной y как многочлен n -й степени от x .

$$y_i = \beta_0 + \beta_1 x_i + \beta_2 x_i^2 + \cdots + \beta_m x_i^m + \varepsilon_i, \quad (i = 1, 2, \cdots, n)$$

Матричная форма записи:

$$\vec{y} = X\vec{\beta} + \vec{\varepsilon}$$



Переобучение и недообучение

При подборе полинома в наборе данных нужно следить за степенью полинома, поскольку это может привести к недостаточному или избыточному подбору.

1

Низкая степень

Недообучение — модель слишком простая, не улавливает паттерны

2


Оптимальная степень

Хорошая подгонка — модель правильно описывает данные


3

Высокая степень

Переобучение — модель запоминает шум, плохо обобщает




Underfitting



Overfitting

Ridge Regression




Ridge Regression

Гребневая регрессия используется при мультиколлинеарности — когда независимые переменные сильно коррелируют. Она регулирует все параметры одинаково, улучшая оценки на стоимость допустимой погрешности.

$$\operatorname{argmin}_{\beta \in \mathbb{R}^p} \underbrace{\|y - X\beta\|_2^2}_{\text{Loss}} + \underbrace{\lambda \|\beta\|_2^2}_{\text{Penalty}}$$

Первый член — член с наименьшими квадратами, второй — множитель Лагранжа ограничения. При $\lambda=0$ оценка сводится к обычным наименьшим квадратам. Это регуляризация L2 — коэффициенты становятся меньше, но не зануляются.

Lasso Regression




Lasso Regression

Как и ridge, lasso увеличивает абсолютный размер коэффициентов регрессии. Штрафной член представляет собой абсолютное значение, а не квадраты.

$$\operatorname{argmin}_{\beta \in \mathbb{R}^p} \underbrace{\|y - x\beta\|_2^2}_{\text{Loss}} + \underbrace{\lambda \|\beta\|_1}_{\text{Penalty}}$$

Большой штраф приводит к уменьшению оценки до абсолютного нуля, исключая переменную. Например, при 5 похожих признаках lasso выбирает один случайный признак, остальные зануляет. Используется регуляризация L1.

ElasticNet Regression



$$\hat{\beta} = \operatorname{argmin}_{\beta} (\|y - X\beta\|^2 + \lambda_2 \|\beta\|^2 + \lambda_1 \|\beta\|_1)$$



Гибридный подход

Комбинация lasso и ridge регрессий с регуляризацией L1 и L2



Групповое поведение

Выбирает все коррелирующие предикторы, а не один случайный



Сбалансированное сжатие

Сжимает все признаки группы одинаково, оставляя их ненулевыми

Байесовская Линейная Регрессия

Байесовская линейная регрессия находит не только наилучшее значение параметров, но и определяет апостериорное распределение. Основана на теореме Байеса и идеально подходит при недостатке данных.

Теорема Байеса

$$P(A|B) = \frac{P(B|A) * P(A)}{P(B)}$$

- $P(A|B)$ - вероятность гипотезы A при наступлении события B
- $P(A)$ - априорная вероятность гипотезы A
- $P(B|A)$ - вероятность наступления события B при истинности гипотезы A
- $P(B)$ - априорная вероятность наступления события B

Логистическая Регрессия

В отличие от линейной регрессии с непрерывными прогнозами, логистическая регрессия даёт дискретные результаты: двоичные значения (да/нет, верно/ложно).



Бинарная

Двоичные выходные данные: да/нет, верно/ложно




Порядковая

Порядковые значения: низкий, средний, высокий





Мультиномиальная

Несколько классов: кошка, собака, лев, коза



Механизм Логистической Регрессии

Логистическая регрессия — классифицирующий алгоритм, достигаемый передачей выходных данных через функцию активации, отображающую действительное число в 0 или 1.



Значение функции в диапазоне от 0 до 1.

Если вероятность > 0.5 , результат оценивается как 1, иначе 0.

$$P = \frac{1}{1 + e^{-(a+bX)}}$$



Use Python's #1 machine learning library from Node.js

Реализация Линейной Регрессии

Sklearn реализует линейную регрессию в классе `sklearn.linear_model.LinearRegression`.

Импорт

```
from sklearn.linear_model import LinearRegression
```

Обучение

```
linearRegression = LinearRegression().fit(X_train_scaled, label_train)
```

Предсказание

```
y_pred = linearRegression.predict(X_val_scaled)
```

Оценка

```
error_metrics(y_pred, label_val)
```

MSE: 0.17257
RMSE: 0.41542
 R^2 : 0.76726



Реализация Ridge Regression

Sklearn реализует ridge в классе **RidgeCV** — автоматическая версия с кросс-валидацией.
Обычная Ridge требует ручного выбора параметра α (аналог λ)

1

Слишком мал α

Почти нет регуляризации → переобучение
при мультиколлинеарности

2

Оптимальный α

Баланс между смещением и
дисперсией

3

Слишком велик α

Сильное сжатие коэффициентов →
недообучение

Код реализации

```
from sklearn.linear_model import RidgeCV
alphas = [0.007, 0.009, 0.002, 0.01]
ridgeCV = RidgeCV(alphas=alphas, cv=4).fit(X_train_scaled, label_train)
ridgeCV_pre = ridgeCV.predict(X_val_scaled)
print('Alpha found: ', ridgeCV.alpha_)
error_metrics(ridgeCV_pre, label_val)
```

Alpha found: 0.01
MSE: 0.1726
RMSE: 0.4154
 R^2 : 0.76726



Реализация Lasso Regression

Sklearn реализует lasso в классе **LassoCV** — автоматическая версия с кросс-валидацией.

Импорт

```
from sklearn.linear_model import LassoCV
```

Выбор α

```
alphas2 = np.array([1e-6, 5e-6, 1e-5, 2e-5, 1e-3])
```

Обучение

```
lassoCV = LassoCV(alphas=alphas2, max_iter=5e4,  
cv=3).fit(X_train_scaled, label_train)
```

Предсказание


```
lassoCV_pre = lassoCV.predict(X_val_scaled)
```

Оценка

```
error_metrics(lassoCV_pre, label_val)
```

Alfa found: $2e-5$
MSE: 0.17257
RMSE: 0.4154
 R^2 : 0.76726

Regression plot of predicted charge vs actual charge
(Logarithmic scale)



Реализация Байесовской Линейной Регрессии

Sklearn реализует lasso в классе **BayesianRidge**.

Импорт

```
from sklearn.linear_model import BayesianRidge
```

Выбор признаков и целевой переменной

```
features=['AT','V','AP','RH']  
target='PE'
```

Обучение

```
model=BayesianRidge(alpha_1=Alpha1, alpha_2=Alpha2,  
lambda_1=Lambda1, lambda_2=Lambda2)  
model.fit(x_train,y_train)
```

Предсказание

```
y_pred=model.predict(x_test)
```

Вывод метрик

```
print("Accuracy score{:.2f} %\n".format(  
model.score(x_test,y_test)*100))
```


Оценка

```
print("R2 Score: {:.2f} %".format( r2_score(y_test,y_pred)*100))  
  
print("Mean Absolute Error {:.2f}".format(  
mean_absolute_error(y_test,y_pred)))  
  
print("Mean Squared Error {:.2f}".format(  
mean_squared_error(y_test,y_pred)))
```

R2 Score: 92.35 %

Mean Absolute Error 3.74

Mean Squared Error 22.13



Реализация Логистической Регрессии

Sklearn реализует lasso в классе **LogisticRegression**

Импорт

```
from sklearn.linear_model import LogisticRegression
```

Обучение

```
lr = LogisticRegression(solver='liblinear').fit(X_train_scaled,  
label_train)
```

L1-регуляризация

```
lr_l1 = LogisticRegressionCV(Cs=15, cv=4,  
penalty='l1', solver='liblinear').fit(X_train_scaled, label_train)
```

L2-регуляризация

```
lr_l2 = LogisticRegressionCV(Cs=15, cv=4,  
penalty='l2', solver='liblinear').fit(X_train_scaled, label_train)
```

Вывод отчета о классификации

```
from sklearn.metrics import
classification_report

print('Classification report for
Logistic

regression without regularization:')

print(classification_report(label_val,
y_pred['lr']))

print('Classification report for
Logistic regression

with L1(Lasso) regularization:')

print(classification_report(label_val,
y_pred['l1']))

print('Classification report for
Logistic regression

with L2(Ridge) regularization:')

print(classification_report(label_val,
y_pred['l2']))
```

➤ Classification report for Logistic regression without regularization:

	precision	recall	f1-score	support
0	0.75	0.91	0.82	610
1	0.71	0.44	0.54	321
accuracy			0.75	931
macro avg	0.73	0.67	0.68	931
weighted avg	0.74	0.75	0.73	931

Classification report for Logistic regression with L1(Lasso) regularization:

	precision	recall	f1-score	support
0	0.75	0.91	0.82	610
1	0.71	0.44	0.54	321
accuracy			0.74	931
macro avg	0.73	0.67	0.68	931
weighted avg	0.74	0.74	0.73	931

Classification report for Logistic regression with L2(Ridge) regularization:

	precision	recall	f1-score	support
0	0.75	0.91	0.82	610
1	0.71	0.43	0.54	321
accuracy			0.74	931
macro avg	0.73	0.67	0.68	931
weighted avg	0.74	0.74	0.72	931

Матрица путаницы

Таблица 2×2 для бинарной классификации, показывающая правильные и неправильные предсказания.

True Positive

Модель правильно угадала класс 1 (уволился)

True Negative


Модель правильно угадала класс 0 (остался)

False Positive

Ошибка: сказала «уйдет», а человек остался

False Negative

Ошибка: сказала «останется», а человек уволился



Рекомендации по выбору модели



Предварительный анализ

Всегда начинаем с анализа данных



Линейная связь

Если связь линейная и данных много → обычная линейная регрессия



Мультиколлинеарность

Есть мультиколлинеарность → Ridge



Отбор признаков

Много признаков, нужен отбор → Lasso



Комбинирование

И то, и другое → Elastic Net



Мало данных

Мало данных → BayesianRidge




Категории

Нужно предсказывать категорию → логистическая регрессия

Выводы

Регрессионный анализ — один из самых изученных и до сих пор самых полезных инструментов в Data Science.



Анализ данных



Разные модели



Метрики



Улучшение

Ключ к успеху — не заикливаться на одной модели, а пробовать разные варианты и смотреть на метрики. Если плохо — возвращаться к данным и улучшать признаки.